

PARIS DESCARTES UNIVERSITY

BUISNESS INTELLIGENCE

Projet Traitement de texte

Étudiant : Ilyes ZEMALACHE

Professeur : Rafika Boutalbi

02 Novembre 2019

Table des matières

1	Introduction	2
2	Nettoyage	2
3	DocTerm	3
4	Qlik Sense Interprétation	5
5	Application de k-means	5
6	Conclusion	6

Résumé

Sur cette étude on va passer par plusieurs étapes, tout d'abord on va lire le fichier, et bien l'organiser dans un data Frame, ensuite faire le nettoyage du text, afin d'appliquer les fonctions nécessaires pour l'obtention de la matrice doc termes, on appliquera aussi un skmeans sur une partie de donnée, et le tout sera résumé dans un tableau de bord de l'outil Qlik Sense.

1 Introduction

Nous disposons d'un fichier texte contenant des informations sur des articles scientifiques parus dans des revues et conférences. Ces informations comprennent :

- Le titre de l'article,
- Le ou les auteurs,
- L'année de publication,
- Nom de la revue (ou de la conférence)
- Les citations entre articles.

Nous souhaitons faire une étude sur ce document, tout en passant par une série d'opérations.

2 Nettoyage

Grace à la fonction remplissage, qui traite ligne par ligne notre document on réussit à remplir notre data frame "df".

Ce qu'il nous reste à compléter maintenant, c'est l'exportation dans un fichier csv, juste avant de faire cela, on fait un petit nettoyage, qui se présente sur la suppression de toutes les lignes avec des abstract et/ou auteur qui ont une valeur "NA".




FIGURE 1 - Data Frame

3 DocTerm

Grâce à la fonction "DocumentTermMatrix" du package tm sur R, on réalise la matrice document termes, on obtient un fichier de taille énorme c'est à dire + de 2.6 GO, ce qui nous oblige de retirer les termes les moins fréquents grâce à la fonction "removeSparseTerms", on se retrouve avec 1061 termes au lieu de 9000.




FIGURE 2 – Doc Termes

4 Qlik Sense Interprétation




FIGURE 3 – Doc Termes

Tout d'abord, on s'est intéressé aux auteurs les plus productifs, ensuite on a fait le lien avec l'année la plus explosive qui est 2009 avec 26.4% d'articles, on voit aussi que les revues les plus populaires sont respectivement "DAC" , "IJCAI", "Electr Notes". L'article le plus cité c'était celui qui a comme index "759". On a renforcé notre interpretation avec wordCloud du R, et on a trouvé que les termes "System","Model","Algorithm" sont les plus fréquents.

5 Application de k-means

Sur cette section on s'est intéressé sur une petite partie de notre dataframe, et voila ce qu'on obtient :




FIGURE 4 – Doc Termes

6 Conclusion

Enfin il faut savoir que plusieurs calculs ont été évité, à cause du volume très grand des formats CSV obtenu, comme par exemple la matrice co-Auteur qui pese 67GB, et citations.

On a essaye d'exploiter le maximum notre dataframe pour avoir des informations pertinentes .

Lien GitHub